

Disciplina de Tópicos em Fundamentos e Métodos da Computação

Atividade 01

https://github.com/thiagodepaulo/nlp/blob/main/aula_1/exercicio1.md

O código foi alterado para atender o feedback do professor que observou que eu treinei o tokenizador em apenas um documento.

Atividade: Aplicação do Algoritmo BPE

Objetivo

Nesta atividade, você irá reproduzir o algoritmo de Byte Pair Encoding (BPE) conforme demonstrado no vídeo Let's build the GPT Tokenizer e aplicá-lo a um conjunto de dados fornecido pelo professor. A atividade tem como foco o entendimento prático de compressão de texto e subpalavras em Processamento de Linguagem Natural.

Instruções

Assista ao vídeo tutorial Let's build the GPT Tokenizer. O vídeo explica como o algoritmo de BPE funciona, abordando tanto a parte teórica quanto a prática em Python. Certifique-se de entender o conceito e o funcionamento do algoritmo antes de iniciar a codificação.

Reproduza o código em Python descrito no vídeo. Não copie diretamente o código fornecido. Reescreva o código em seu próprio ambiente para garantir que compreendeu cada parte.

Aplicação em Notebook: Após a reprodução do código em Python, utilize um notebook Jupyter ou Colab para aplicar o algoritmo BPE no conjunto de dados fornecido pelo professor. Certifique-se de carregar o conjunto de dados corretamente e implementar os passos necessários para executar o BPE no conteúdo textual. Não implemente o código diretamente no Notebook, apenas importe as funções do tokenizador que você implementou. Deixe o Notebook pequeno e simples!

Conjunto de Dados

PROF O arquivo contendo uma coleção de textos pode ser baixado no link [Aqui!](#).

O corpus é formado por vários arquivos no formato '.json'. Processe o BPE em todos os arquivos.

O que deve ser entregue:

O arquivo .py contendo a implementação do algoritmo BPE com base no que foi ensinado no vídeo.

Um notebook (.ipynb) que:

Carrega o conjunto de dados fornecido.

Importa as funções implementadas do algoritmo BPE.

Aplica o algoritmo BPE no conjunto de dados.

Exibe os resultados da segmentação das subpalavras no final do processo.

Crie um repositório no github para a disciplina e coloque seus arquivos. Coloque os arquivos desta atividade em uma pasta separada -- chame a pasta de Atividade_1.

Coloque a URL do seu github em frente ao seu nome nesta planilha [Aqui](#).

Avaliação

A implementação correta do algoritmo de BPE será avaliada.

O código Python deve ser funcional e bem documentado.

O notebook deve conter as explicações necessárias sobre os passos seguidos e os resultados gerados.

Dica: Certifique-se de que seu código está bem organizado e comentado, explicando a lógica de cada parte da implementação.

Prazo: Submeta a atividade até 29/10/2024 na plataforma da disciplina.