

Disciplina de Tópicos em Fundamentos e Métodos da Computação

Atividade 01 (Aplicação do Algoritmo BPE)

https://github.com/thiagodepaulo/nlp/blob/main/aula_1/exercicio1.md

Objetivo

Nesta atividade, você irá reproduzir o algoritmo de Byte Pair Encoding (BPE) conforme demonstrado no vídeo [Let's build the GPT Tokenizer](#) e aplicá-lo a um conjunto de dados fornecido pelo professor. A atividade tem como foco o entendimento prático de compressão de texto e subpalavras em Processamento de Linguagem Natural.

Instruções

1. Assista ao vídeo tutorial Let's build the GPT Tokenizer. O vídeo explica como o algoritmo de BPE funciona, abordando tanto a parte teórica quanto a prática em Python. Certifique-se de entender o conceito e o funcionamento do algoritmo antes de iniciar a codificação.
2. Reproduza o código em Python descrito no vídeo. Não copie diretamente o código fornecido. Reescreva o código em seu próprio ambiente para garantir que compreendeu cada parte.
3. Aplicação em Notebook: Após a reprodução do código em Python, utilize um notebook Jupyter ou Colab para aplicar o algoritmo BPE no conjunto de dados fornecido pelo professor. Certifique-se de carregar o conjunto de dados corretamente e implementar os passos necessários para executar o BPE no conteúdo textual. Não implemente o código diretamente no Notebook, apenas importe as funções do tokenizador que você implementou. Deixe o Notebook pequeno e simples!

Conjunto de Dados

PROF

- O arquivo contendo uma coleção de textos pode ser baixado no link [Aqui!](#).
- O corpus é formado por vários arquivos no formato '.json'. Processe o BPE em todos os arquivos.

O que deve ser entregue:

1. O arquivo `.py` contendo a implementação do algoritmo BPE com base no que foi ensinado no vídeo.
2. Um notebook (`.ipynb`) que:
 - Carrega o conjunto de dados fornecido.
 - Importa as funções implementadas do algoritmo BPE.
 - Aplica o algoritmo BPE no conjunto de dados.
 - Exibe os resultados da segmentação das subpalavras no final do processo.

3. Crie um repositório no github para a disciplina e coloque seus arquivos. Coloque os arquivos desta atividade em uma pasta separada -- chame a pasta de Atividade_1.
4. Coloque a URL do seu github em frente ao seu nome nesta planilha [Aqui!](#).

Avaliação

A implementação correta do algoritmo de BPE será avaliada.

O código Python deve ser funcional e bem documentado.

O notebook deve conter as explicações necessárias sobre os passos seguidos e os resultados gerados.

Dica:

Certifique-se de que seu código está bem organizado e comentado, explicando a lógica de cada parte da implementação.

Prazo:

Submeta a atividade até 29/10/2024 na plataforma da disciplina.