

## Disciplina de Tópicos em Fundamentos e Métodos da Computação

### Atividade 02

[https://github.com/thiagodepaulo/nlp/blob/main/aula\\_2/exercicio2.md](https://github.com/thiagodepaulo/nlp/blob/main/aula_2/exercicio2.md)

Atividade: Criação de Modelo de Bigrama para Geração de Texto

#### Objetivo

Nesta atividade, você irá construir um modelo de bigrama para geração de texto. A atividade será realizada utilizando o tokenizador que você implementou na atividade anterior (algoritmo BPE). O objetivo é treinar e avaliar o modelo, bem como medir sua perplexidade em um conjunto de dados de teste.

#### Instruções

##### Preparação dos Dados:

Utilize o tokenizador implementado na atividade anterior para segmentar o conjunto de dados fornecido.

Divida os arquivos em treino (80%) e teste (20%) de forma aleatória.

##### Implementação do Modelo de Bigrama:

Implemente um modelo de bigrama em Python. O modelo deve calcular a probabilidade condicional de uma palavra dado a palavra anterior com base nos dados de treino.

A saída deve ser o modelo que calcula a distribuição de probabilidade das palavras baseando-se nas palavras anteriores.

##### Cálculo da Perplexidade:

Aplique o modelo de bigrama no conjunto de dados de teste para calcular a perplexidade, uma métrica usada para avaliar a capacidade preditiva do modelo. A perplexidade indica o quão bem o modelo prevê o próximo termo em uma sequência.

##### Geração de Texto:

Implemente uma função que gera texto a partir do modelo de bigrama.

No notebook, gere um exemplo de texto com pelo menos 20 tokens para demonstrar o funcionamento do modelo.

##### Entrega:

Crie um arquivo .py com a implementação do modelo bigrama e a função de cálculo de perplexidade. Certifique-se de que o código está funcional e bem documentado.

No notebook, carregue o modelo e o conjunto de dados de teste, e aplique as seguintes funções:

Exemplo de geração de texto a partir do modelo de bigrama.

Apresentação do cálculo da perplexidade para o conjunto de teste.

##### Estrutura Esperada

Arquivo Python (.py):

Código do modelo de bigrama.

Função de cálculo de perplexidade.

Função de geração de texto.

Notebook (.ipynb):

Apresentação do exemplo de geração de texto.

Cálculo e exibição da perplexidade do modelo no conjunto de teste.

Dicas

Utilize a fórmula da perplexidade indicada no livro texto da disciplina -- [Link do Livro](#).

No vídeo do Andrej Karpathy ([link do vídeo](#)) ele descreve e implementa um modelo bigrama.

Aproveitem a ótima aula dele usem algumas facilidades como a função multinomial para amostragem. A partir de 1h desse vídeo ele implementa usando Redes Neurais, ignorem essa parte! (trabalho futuro?)

Para a geração de texto, experimente iniciar com uma palavra ou token aleatório do vocabulário e gere a sequência a partir do modelo até atingir o número desejado de tokens.

Avaliação

Implementação correta do modelo de bigrama e da função de perplexidade.

Organização e clareza do código.

Documentação e comentários explicativos.

Correta aplicação do tokenizador desenvolvido anteriormente.

Prazo: Submeta a atividade até 12/11/2024 na plataforma da disciplina (plataforma a definir).