

Atividade 02 (Criação de Modelo de Bigrama para Geração de Texto)

https://github.com/thiagodepaulo/nlp/blob/main/aula_2/exercicio2.md

Objetivo

Nesta atividade, você irá construir um modelo de bigrama para geração de texto. A atividade será realizada utilizando o tokenizador que você implementou na atividade anterior (algoritmo BPE). O objetivo é treinar e avaliar o modelo, bem como medir sua perplexidade em um conjunto de dados de teste.

Instruções

1. Preparação dos Dados:

- Utilize o tokenizador implementado na atividade anterior para segmentar o conjunto de dados fornecido.
- Divida os arquivos em treino (80%) e teste (20%) de forma aleatória.

2. Implementação do Modelo de Bigrama:

- Implemente um modelo de bigrama em Python. O modelo deve calcular a probabilidade condicional de uma palavra dado a palavra anterior com base nos dados de treino.
- A saída deve ser o modelo que calcula a distribuição de probabilidade das palavras baseando-se nas palavras anteriores.

3. Cálculo da Perplexidade:

- Aplique o modelo de bigrama no conjunto de dados de teste para calcular a perplexidade, uma métrica usada para avaliar a capacidade preditiva do modelo. A perplexidade indica o quão bem o modelo prevê o próximo termo em uma sequência.

4. Geração de Texto:

- Implemente uma função que gera texto a partir do modelo de bigrama.
- No notebook, gere um exemplo de texto com pelo menos 20 tokens para demonstrar o funcionamento do modelo.

5. Entrega:

- Crie um arquivo .py com a implementação do modelo bigrama e a função de cálculo de perplexidade. Certifique-se de que o código está funcional e bem documentado.
- No notebook, carregue o modelo e o conjunto de dados de teste, e aplique as seguintes funções:
 - Exemplo de geração de texto a partir do modelo de bigrama.
 - Apresentação do cálculo da perplexidade para o conjunto de teste.

Estrutura Esperada

1. Arquivo Python (.py):

- Código do modelo de bigrama.
- Função de cálculo de perplexidade.
- Função de geração de texto.

2. Notebook (.ipynb):

- Apresentação do exemplo de geração de texto.
- Cálculo e exibição da perplexidade do modelo no conjunto de teste.

Dicas

- Utilize a fórmula da perplexidade indicada no livro texto da disciplina [Speech and Language Processing \(3rd ed. draft\) Dan Jurafsky and James H. Martin](#)
- No [vídeo do Andrej Karpathy](#) ele descreve e implementa um modelo bigrama. Aproveitem a ótima aula dele usem algumas facilidades como a função multinomial para amostragem. A partir de 1h desse vídeo ele implementa usando Redes Neurais, ignorem essa parte! (trabalho futuro?)
- Para a geração de texto, experimente iniciar com uma palavra ou token aleatório do vocabulário e gere a sequência a partir do modelo até atingir o número desejado de tokens.
- Utilize o tokenizador implementado na atividade anterior para segmentar o conjunto de dados fornecido.
- Utilizem um tokenizador de sentenças como o [sent_tokenize](#) do nltk
- Pode utilizar outro tokenizador, como o tiktoken ou nltk
- Para cada documento segmente em sentenças utilizando o sent_tokenizer, ou algum outro segmentador em sentenças (o SpaCy faz isso também, mas acho caro computacionalmente. Eu não tive boas experiências com o SpaCy, apesar dele ser popular)
- Criem tokens especiais para início e fim de sentenças. Se forem utilizar o tiktoken, por exemplo, ver quais os tokens especiais para início e fim de sentenças (no tiktoken é <|startoftext|> e <|endoftext|>).
- Divida os arquivos em treino (80%) e teste (20%) de forma aleatória.

Avaliação

- Implementação correta do modelo de bigrama e da função de perplexidade.
- Organização e clareza do código.
- Documentação e comentários explicativos.
- Correta aplicação do tokenizador desenvolvido anteriormente.

Prazo

Submeta a atividade até 12/11/2024 na plataforma da disciplina (plataforma a definir).

Prazo